

智能问答系统大作业

背景知识

检索增强生成（Retrieval-augmented Generation, RAG）是一种结合了信息检索与文本生成的技术，旨在提升生成模型在知识密集型任务中的表现。RAG通过从外部知识库或文档中检索相关信息，并将其作为输入提供给生成模型，从而生成更准确、更丰富的回答。RAG技术已经广泛应用于问答系统、对话生成和文档摘要等领域，显著提升了生成内容的质量和可靠性。

作业要求

在本次作业中，你需要实现一个通用领域问答的RAG系统，要求：

- (1) 实现一个完整的RAG系统，**至少包括检索器和生成器(LLM，通过调用API实现)两部分**，能够针对用户给出的问题进行回答，同时选取合适的评价指标进行评估。除此之外，你应该至少在以下额外功能中选择两项完成：
 - 不同原理的检索器
 - 查询改写器
 - 重排序器
 - 思维链推理
 - 其他自选功能
- (2) 设计一个UI交互界面，能够支持用户在线的问答。
- (3) 完成验证集和测试集上查询的回答。

模型和数据

- LLM：使用[硅基流动](#)提供的免费API，请自行注册账号。为了便于进行性能比较，我们要求统一使用 Qwen2.5-7B-Instruct 模型作为生成器进行试验。当然如果有条件，你也可以本地部署该模型。
- 语料库：一个大规模维基百科语料库，可以在[网盘链接](#)中下载 corpus.zip 文件或者[HF链接](#)中下载 wiki18_100w.zip 文件。
- 验证集/测试集：我们在[网盘链接](#)上提供了一个验证集(dev.jsonl)和测试集(test.jsonl)，用于衡量你所实现系统的性能，二者的数据分布基本相同。你需要在实验报告中选取合适的指标(要求至少包含EM和F1)并汇报在验证集上的表现，同时提交你的方法在验证集和测试集上的回复。

提交内容

- 全部代码。其中应当包括README文件说明代码的架构及使用方法。请不要包含中间结果(如索引等)和数据集文件。
- 验证集和测试集上的答案，命名为 `dev.txt` 或 `test.txt`，每一行表示验证集或测试集中对应行数查询的答案。
- 实验报告。**需要包含对不同模块的消融分析、参数设置等分析等。**请不要包含大段代码。
- 请将以上内容打包为一个 `<学号>.zip` 的压缩包进行提交，一个小组一位同学提交即可。

评分细则

- 核心功能(50): 至少满足上述的基本要求。其中RAG系统基本功能20分，额外功能20分，交互界面10分。
- 性能评测(20): 助教会对你提交的测试集上的答案进行离线评测，同时你需要对不同的模块/模型在验证集上的表现进行消融实验以及对参数设置进行分析以探究它们各自的影响。
- 主观体验(10): 展示、设计、技术、团队协作、QA。
- 实验报告(20): 简洁、清晰即可。请注明使用了哪些开源资料，参考了他人提供的哪些代码。